



UNIVERSIDAD DE VALLADOLID

Facultad de Ciencias Económicas y Empresariales

TRABAJO FIN DE GRADO

GRADO EN Administración y Dirección de Empresas

Caracterización de los rendimientos diarios de los mercados energéticos

Autor:

D. César Redondo Urdiales

Tutora:

Ana Pérez Espartero

Valladolid, 11 de febrero de 2023

TÍTULO: **Caracterización de los rendimientos
diarios de los mercados energéticos**

AUTOR: **D. César Redondo Urdiales**

TUTORES: **Dña. Ana Pérez Espartero**

DEPARTAMENTO: **Departamento de Economía Aplicada**

Resumen del TFG

Este trabajo analiza las propiedades dinámicas y marginales de la distribución de los rendimientos del mercado energético (petróleo, gas y carbón) con el fin de ver si presentan una serie de características (*Stylized Facts*) que ya han sido ampliamente documentadas en los rendimientos de los activos financieros.

El TFG comienza describiendo los mercados energéticos y los datos a analizar, después se aplican técnicas de estadística descriptiva y contrastes de normalidad, para analizar las características de las distribuciones marginales de los rendimientos, seguidamente se analizan las propiedades dinámicas, mediante autocorrelaciones y correlaciones cruzadas de diferentes transformaciones de los rendimientos. Por último, se revisa la sensibilidad de las propiedades dinámicas ante la presencia de datos atípicos.

Palabras clave

Materias primas, hecho estilizado, correlación, efecto de Taylor, efecto de apalancamiento, rendimiento compuesto, volatilidad.

Abstract

This paper focuses on analyzing marginal and dynamic properties of energy market prices (oil, gas and coal) in order to see if they meet a series of Stylized Facts that have already been widely documented in financial assets.

It begins by describing the energy markets and the data to be analyzed, then descriptive statistics and normality tests are applied to the marginal distribution of returns, then the dynamic properties of returns are analyzed, by calculating autocorrelations and cross-correlations of different transformations of obtained from the data. Finally, the sensitivity of the dynamic properties in the presence of outliers is reviewed.

Keywords

Commodities, stylized facts, correlation, Taylor effect, Leverage effect, compound return, volatility, logarithmic percentage.

Agradecimientos

A papá, mamá y Sara.

Y a mi tutora Ana Pérez Espartero por proporcionarme los medios, y sus continuas aportaciones a este trabajo.

Tabla de contenido

<i>Resumen del TFG</i>	1
<i>Palabras clave</i>	1
<i>Abstract</i>	1
<i>Keywords</i>	1
<i>Agradecimientos</i>	2
<i>Tabla de figuras</i>	4
<i>Capítulo 1 – Introducción</i>	5
<i>Capítulo 2 – Conceptos preliminares y descripción de los datos</i>	7
2.1. El mercado de la energía	7
2.2. Datos y variables utilizados	10
<i>Capítulo 3 – Regularidades empíricas de la distribución de los rendimientos</i>	14
<i>Capítulo 4 – Propiedades dinámicas de los rendimientos</i>	19
4.1. Incorrelación en los rendimientos	19
4.2. Autocorrelación en los rendimientos cuadráticos y absolutos. Efecto Taylor.	23
4.3. Efecto Leverage	25
<i>Capítulo 5 – Sensibilidad de los resultados ante la presencia de datos atípicos.</i> <i>Medidas de correlación robustas</i>	28
5.1. Estimador robusto de la autocorrelación	28
5.2. Estimador robusto de la autocorrelación de los cuadrados.	31
5.3. Estimador robusto de las autocorrelaciones cruzadas.	31
<i>Capítulo 6 - Conclusiones</i>	33
<i>Referencias</i>	34

Tabla de figuras

FIGURA 1 – PRODUCCIÓN DE ENERGÍA POR REGIONES EN 2019 [7].....	7
FIGURA 2 – CONSUMO DE ENERGÍA POR REGIONES EN 2019. WORLD BUNKERS HACE REFERENCIA A LAS ZONAS INTERNACIONALES DE AVIACIÓN Y NAVEGACIÓN [7].	8
FIGURA 3-PRECIOS, RENDIMIENTOS DIARIOS Y VOLATILIDAD DEL GAS, PETRÓLEO Y CARBÓN ENTRE 2008 Y 2022.	11
FIGURA 4- HISTOGRAMAS JUNTO A FUNCIÓN DE DISTRIBUCIÓN NORMAL, BOX-PLOTS, Y QQ-PLOTS.....	16
FIGURA 5- FUNCIÓN DE AUTOCORRELACIÓN PARA LOS RENDIMIENTO, SUS VALORES ABSOLUTOS Y SUS CUADRADOS.....	20
FIGURA 6 – CORRELACIÓN ENTRE $rt\theta$ Y $rt - h\theta$ PARA DIFERENTES θ . SIENDO rt EL RENDIMIENTO DE CADA COMMODITY.	23
FIGURA 7-CORRELACIÓN CRUZADA ENTRE LOS RENDIMIENTOS Y SUS CUDRADOS, Y LOS RENDIMIENTOS Y SUS ABSOLUTOS.....	26
FIGURA 8-FUNCIONES DE AUTOCORRELACIÓN DE LOS RENDIMIENTOS, AUTOCORRELACIÓN DE LOS RENDIMIENTOS AL CUADRADO Y CORRELACIONES CRUZADAS ENTRE LOS RENDIMIENTOS Y LOS RENDIMIENTOS AL CUADRADO.....	30

Capítulo 1 – Introducción

En 1994 Granger y Ding publicaron un estudio [1] en el que analizaban la evolución temporal de los rendimientos, en una amplia gama de series de precios de acciones, commodities, tipos de interés, y tipos de cambio. El objetivo del trabajo era ver si los diferentes mercados comparten características similares, y para la mayoría de casos así pareció ser. A partir de ahí, surgieron muchos estudios sobre la evolución temporal de los rendimientos de activos financieros, estos estudios analizan diferentes activos en diferentes mercados, y muestran que todos ellos comparten una serie de características estadísticas conocidas como *Stylized Facts*. Estas características son las siguientes:

- a) Los rendimientos financieros no siguen una distribución normal y están incorrelacionados.
- b) Existe autocorrelación positiva y persistente en los rendimientos absolutos y en sus cuadrados, además, la primera suele ser mayor que la segunda.
- c) Los mercados responden de forma asimétrica a caídas o subidas de los precios, presentando mayor volatilidad tras caídas en los precios.

Sin embargo, no existen tantos estudios que analicen patrones en la evolución temporal de los rendimientos en el mercado de la energía. Por otra parte, el precio de la energía se ha convertido en un tema de rabiosa actualidad en el último año con la subida de sus precios. Precisamente, el principal objetivo de este trabajo es ver si algunos de los *Stylized Facts* que se observan en los mercados financieros, aparecen también en el mercado energético. El otro objetivo del trabajo es analizar si alguna de esas características típicas de los rendimientos pueden deberse al efecto adverso de la presencia de datos atípicos, que podrían sesgar los valores de los estadísticos utilizados. Para la consecución de este objetivo, se utilizarán medidas de autocorrelación robustas alternativas a las habituales.

Como comentaremos más adelante, a pesar de la transición energética, las principales materias primas del mercado energético siguen siendo los combustibles fósiles. Por ello, este trabajo se centra en el análisis de la evolución de los precios diarios de los futuros del petróleo (Brent), gas y carbón. El periodo analizado va desde enero de 2008 hasta mayo de 2022, esto nos permite cubrir la bancarrota de Lehman Brothers, la primavera árabe, la explosión del *fracking*, la crisis del Covid y el inicio de la guerra entre Rusia y Ucrania.

El trabajo se compone de seis capítulos. El primero de ellos es este mismo, la Introducción, en la que explicamos la motivación de este trabajo y los objetivos a alcanzar. El segundo capítulo describe el mercado a analizar así como los datos utilizados. El tercero se centra en analizar las principales características de la distribución marginal de las tres series de rendimientos analizadas. En el cuarto analizamos las propiedades dinámicas de dichas series, centrándonos en las autocorrelaciones de los propios rendimientos y de algunas transformaciones suyas, como cuadrados y valores absolutos que suelen considerarse *proxies* de la volatilidad. Además analizamos las correlaciones cruzadas, entre los rendimientos pasados y la volatilidad, lo que nos permitirá estudiar el denominado *leverage effect*. En el capítulo quinto estudiamos la sensibilidad frente a valores atípicos de los resultados obtenidos en

el capítulo cuarto, y proponemos medidas robustas alternativas. Finalmente en el capítulo 6 resumimos las principales conclusiones del trabajo.

Capítulo 2 – Conceptos preliminares y descripción de los datos

2.1. El mercado de la energía

El mercado de la energía es un mercado compuesto por diferentes materias primas (petróleo, carbón, gas...) y por la electricidad (que se puede obtener tanto de las conocidas energías renovables como de las energías fósiles). A pesar del rápido crecimiento de las energías renovables durante la última década, los combustibles fósiles aún dominan el consumo mundial de energía, proporcionando el 85 % de las necesidades energéticas mundiales en 2018 [2].

Los recursos energéticos suponen un elemento clave en la economía, puesto que son uno de los primeros eslabones de la economía, y de sus precios depende en gran medida la inflación.

Los siguientes gráficos muestran, respectivamente, la producción y el consumo de energía por región en porcentaje sobre el total mundial:

TOTAL 2019 = 14745 Mtoe




Figura 1 – Producción de energía por regiones en 2019 [3].

TOTAL 2019 = 9983 Mtoe




Figura 2 – Consumo de energía por regiones en 2019. World Bunkers hace referencia a las zonas internacionales de aviación y navegación [3].

Para hacernos una idea general, a continuación vamos a hablar sobre los principales países exportadores de energías fósiles. EEUU fue el principal productor de petróleo del mundo en 2018, y China es uno de los 5 principales productores del mundo, por delante de todos los países del Medio Oriente, excepto Arabia Saudita. EEUU también encabeza la producción de gas natural, seguido de Rusia e Irán. Respecto al carbón, China es el principal productor, con el 46% del total mundial en 2018, seguido de India y EEUU. En resumen, EEUU encabeza la producción mundial de energías fósiles, seguido de Rusia e Irán [2].

Por su parte, la Unión Europea es importadora de energías fósiles. En 2020, el principal producto energético importado fueron los derivados del petróleo (incluido el petróleo crudo, que es el componente principal), que representaron casi dos tercios de las importaciones de energía en la UE, seguidos del gas natural (27 %) y los combustibles fósiles sólidos (5 %). Rusia ha sido hasta el momento el principal proveedor de la UE de petróleo crudo, gas natural y combustibles fósiles sólidos. Por ejemplo, en 2020, casi las tres cuartas partes de las importaciones extracomunitarias de petróleo crudo procedían de Rusia (29 %), Estados Unidos (9 %), Noruega (8 %), Arabia Saudí y Reino Unido (ambos el 7 %), así como de Kazajistán y Nigeria (ambos con un 6 %). Un análisis similar muestra que más de las tres cuartas partes de las importaciones de gas natural de la UE procedieron de Rusia (43 %), Noruega (21 %), Argelia (8 %) y Qatar (5 %), mientras que más de la mitad de las importaciones de combustible fósil sólido (principalmente carbón) procedían de Rusia (54 %), seguida de los Estados Unidos (16 %) y Australia (14 %) [4].

Lo que exporta cada país, y en qué porcentaje, da una imagen incompleta de este mercado. Puesto que el peso de esta partida en las cuentas nacionales, sobre el total del PIB del país, es muy diferente de uno a otro, a cada país le afecta de una manera diferente los cambios que se puedan producir en el mercado energético.

Uno de los términos más conocidos del mercado financiero es el de *commodity*. Un *commodity* es un material tangible que se puede comerciar, comprar o vender. Al

encontrarse sin procesar, no posee ningún valor añadido o diferencial más allá de su proveniencia, por eso se suele usar como materia prima para fabricar productos más refinados. Los commodities son un elemento productivo básico, lo cual los convierte en un activo muy interesante para el comercio. Los diferentes tipos de commodities se clasifican en grupos para facilitar su comercialización: granos, ganaderías, energético, metales, softs.

Por otro lado, cabe señalar que existen dos tipos de mercados de commodities, el mercado al contado, en el que pagas al contado por la materia prima y se te entrega inmediatamente y el mercado de los futuros. En el mercado de futuros o bolsas de commodities se negocian las materias primas mediante contratos de futuros en los que se fijan por adelantado la cantidad y el precio para una venta posterior. Esa negociación es similar a la compraventa de acciones, de manera que existen brokers de futuros que adquieren contratos que pueden ser revendidos o recomprados.

En el mundo existen diferentes bolsas de futuros donde se negocian los commodities. Por ejemplo, la DCE de China y la CBOT de Estados Unidos son las principales bolsas para comerciar productos agrícolas. En cambio, la LME de Londres, la NYMEX de Nueva York, la SHFE de Shanghái y la MCX de India son las principales bolsas donde se negocian los metales. Los commodities del sector energético tienen su epicentro en la NYMEX de Nueva York, la ICE del Reino Unido, la TOCOM de Tokio y la DCE de China [5].

Además de los futuros también se comercializan un par de derivados financieros (commodities) más, los *swaps* y las opciones. Los swaps son parecidos a los futuros pero el precio tiene una parte fija y otra variable, y las opciones son acuerdos entre dos partes que dan al comprador de la opción el derecho, pero no la obligación, de comprar o vender a un precio especificado en o antes de una fecha futura específica.

La industria de la energía y sus mercados asociados son complejos y están influenciados por muchos factores diferentes. Además, estos mercados experimentan por sí mismos una gran volatilidad en los precios. Al igual que el resto de mercados, los mercados energéticos también son afectados por la entrada de dinero con fines especulativos, lo cual afecta a la volatilidad de sus precios. Los historiadores recuerdan los incidentes más turbulentos en el pasado reciente de la industria, tal como la crisis del precio del petróleo de 1973 y la Guerra del Golfo de 1991, donde el Dow Jones llegó a disminuir un 10,6 % y un 4 % de su valor respectivamente [6], como hitos clave en la historia de la economía. También cabe reseñar la histórica y sostenida subida de precios observada en el mercados mundiales de petróleo y gas entre 2003 y 2006 [7], periodo de tiempo en el que el precio llegó casi a triplicarse.

Esta volatilidad inherente a los mercados y esta presencia de valores atípicos asociados a eventos puntuales que afectan a dichos mercados serán objeto de estudio en los siguientes capítulos.

2.2. Datos y variables utilizados

Como ya dijimos en la Introducción, en este trabajo vamos a centrarnos en los rendimientos de los futuros del petróleo, el gas y el carbón.

Cuando se trata de petróleo físico, existen diferentes tipos. Los más comercializados son el crudo Brent del Mar del Norte (comúnmente conocido como "crudo Brent") y el West Texas Intermediate (comúnmente conocido como "WTI"). Brent es petróleo que se produce en los campos petroleros de Brent y otros sitios en el Mar del Norte. Ambos tipos de petróleo son similares, y la evolución de sus precios también. En este trabajo emplearemos el petróleo Brent por ser el más usado a nivel mundial.

Respecto al gas, hemos elegido los precios de los futuros del gas natural en el mercado NYMEX, por ser el precio de referencia en EEUU. Y por último para el carbón hemos escogido los precios de los futuros de Newcastle (Australia) por ser el punto de referencia para el mercado asiático (China e India son los mayores consumidores de carbón del planeta).

Para calcular las series diarias de rendimientos emplearemos los precios diarios de cierre, y en particular utilizaremos los denominados *compound returns* que son los habitualmente analizados. Si denotamos por x_t el precio de cierre del día t , se define el rendimiento del día t que denotamos y_t como:

$$Y_t = 100 * \ln \left(\frac{X_t}{X_{t-1}} \right)$$

Esta forma de definir los rendimientos es la habitual cuando se trabaja con precios de activos financieros. Por otra parte, como señala Peña (2001, p. 168-169)[8], la diferencia logarítmica es aproximadamente igual al crecimiento relativo de la serie de precios y además, como demuestran Tornqvist et al (1985)[9], éste es el único indicador simétrico y aditivo del cambio relativo y debería utilizarse en lugar de las tasas de variación habituales que son asimétricas y no aditivas [10].

El periodo temporal escogido es entre 2008 y mayo de 2022, y la longitud de las muestras son respectivamente de 3418, 3723 y 3730 para el carbón, gas y petróleo. Todos los datos con los que hemos realizado los gráficos y los diferentes cálculos han sido obtenidos de [11]. Además todos los gráficos y cálculos del documento así como los datos se pueden encontrar en [12].

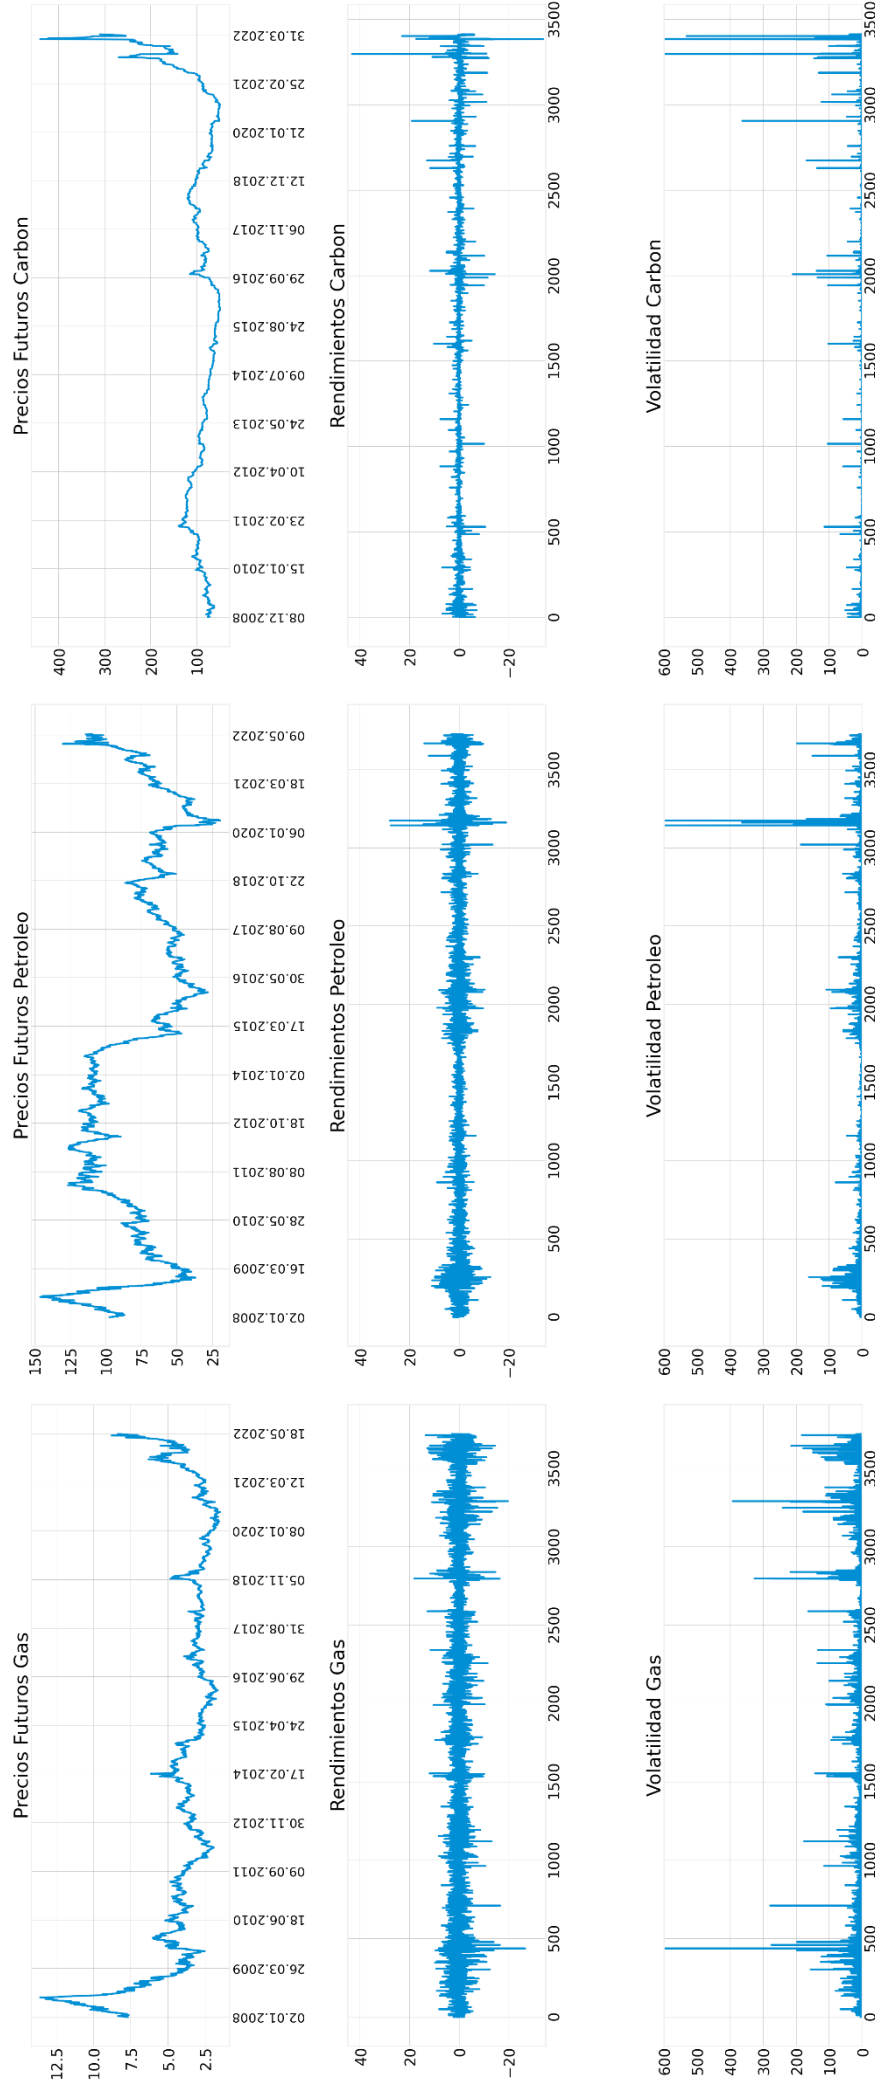


Figura 3-Precios, rendimientos diarios y volatilidad del gas, petróleo y carbón entre 2008 y 2022.

La **Figura 3** muestra la evolución diaria de los precios (paneles superiores), los rendimientos (paneles centrales) y la volatilidad (paneles inferiores) de las tres series analizadas. Como se puede apreciar en la **Figura 3**, desde que comenzó la invasión a Ucrania en febrero de 2022 los precios del carbón se han desplomado, en contraste con los precios del gas y del petróleo, que han subido considerablemente. Según un estudio del ING [13] esto se debe a tres razones:

- La venta de derechos de carbón con el fin de obtener liquidez y permitirse pagar una luz y un gas más caros en el futuro.
- Las expectativas de una menor producción dada la guerra y el incremento de los precios de la energía.
- Efecto bola de nieve debido a la caída del mercado.

Por otra parte, en la **Figura 3** también se puede apreciar que, tras la pandemia hubo un incremento del precio del petróleo y el gas debido al crecimiento de la demanda por encima de la oferta, lo cual, sumado a la falta de inversión en el sector (debido a la transición energética) llevó a que el precio de los combustibles fósiles fuesen tan altos independientemente del conflicto bélico posterior entre Rusia y Ucrania. Hasta antes del bloqueo de gas ruso, las sanciones directas sobre Rusia han supuesto un factor poco relevante en la subida de los precios de los combustibles fósiles. Lo más relevante fueron las sanciones que afectaron al transporte de materias primas, puesto que Rusia y Ucrania conforman el 30% de las producciones mundiales de trigo y el 15% de maíz, y además Rusia exporta un 16% del total del mercado de los fertilizantes [14].

La UE ya ha anunciado un acuerdo de bloqueo al gas ruso. Lo cual ha supuesto un gran reto dada la alta dependencia energética de la UE, y en especial con este país. EEUU apoyó esta decisión y la UE anunció que ayudaría al bloqueo, asegurando 15 mil millones de metros cúbicos adicionales de gas natural licuado para fin de año [15]. Pero la producción de gas es limitada, lo que aumentará la competencia en el mercado, y aumentará los precios del gas todavía más.

En cambio, si observamos el inicio de las series, podemos ver los efectos de la crisis de 2008, donde se produjo una fuerte subida de los precios del gas y el petróleo, seguida de un desplome de estos, llegando a estar por debajo de la mitad del precio máximo alcanzado en ambas series.

En la **Figura 3** también se muestra la evolución de las series de rendimientos diarios y de sus cuadrados, considerada esta última serie por algunos autores como una aproximación de la volatilidad. Los rendimientos al cuadrado se emplean como medida de volatilidad, dado que los rendimientos diarios comúnmente presentan un promedio estadísticamente igual a cero; entonces, el rendimiento al cuadrado equivale a la dispersión cuadrática alrededor de la media ([16] y Ruiz y Veiga, 2008).

El *volatility clustering* es un conocido *Stylized fact* de los activos financieros: su volatilidad no es constante y se presenta agrupada, lo que significa que periodos de alta volatilidad suelen preceder a periodos de alta volatilidad, viceversa. Como podemos ver, la volatilidad en los rendimientos dista de ser constante y se alternan periodos de relativa calma seguidos de otros periodos con mayores oscilaciones alrededor de la media. Por ejemplo, en la serie de rendimientos del petróleo, al principio se observa un periodo de relativa calma seguido de otro de mayor volatilidad seguido de otro periodo

largo de pocas oscilaciones y, finalmente, se observa un periodo de gran volatilidad. Nótese además que los periodos de mayor volatilidad van asociados a caídas de los precios. Esta propiedad, denominada efecto apalancamiento (*leverage effect*) se analizará con más detalle más adelante.

En cuanto a los *outliers*, el máximo atípico del compound return del gas tiene valor 26.77 con signo negativo y se produjo el 29 de septiembre de 2009, debido a la disminución de la demanda derivada de la crisis financiera de 2008, se trata de un atípico consecutivo, con signo distinto al del día anterior. El máximo atípico del petróleo es de 27.97 con signo positivo y se produjo el 20 de abril de 2020 debido a la crisis del COVID, es un atípico consecutivo con el mismo signo que el del día anterior pero distinto al del día siguiente. Por último, el máximo valor atípico del carbon tiene un valor de 43.24 con signo positivo, el mayor con diferencia si lo comparamos con el del carbon y el del gas, y en general con el resto de valores atípicos de las series. Se produjo el 1 de noviembre de 202, y se trata de un atípico consecutivo con signo distinto al ocurrido dos días después.

Capítulo 3 – Regularidades empíricas de la distribución de los rendimientos

Uno de los *Stylized Fact* de los rendimientos de los activos financieros es que presentan características similares a la distribución normal, en especial su simetría y forma acampanada; pero esta tiende a ser más “picuda” y tener colas más pesadas que la distribución normal [17], es decir, la probabilidad de valores extremos es mayor de la que cabe esperar en un modelo gaussiano. Esta característica se conoce como exceso de curtosis. Debido a ello, los contrastes de normalidad pueden rechazar el supuesto de normalidad para la distribución de los rendimientos financieros [18].

En este capítulo vamos a analizar las principales características de las distribuciones marginales de los rendimientos del mercado energético y veremos si son similares o no a las de los mercados financieros mencionados en el párrafo anterior.

La siguiente tabla contiene las medidas estadísticas descriptivas básicas de los rendimientos diarios del mercado financiero.

	Media Aritmética	Mediana	Desviación Estandar	Máximo	Mínimo	Asimetría	Curtosis
Gas	-0.0008	0	3.1717	18.0540	-26.771	-0.4405	7.3754
Petroleo	-0.0034	-0.0784	2.4259	27.9761	-19.077	0.6778	16.7718
Carbon	-0.0435	0	1.8501	43.2453	-34.057	2.2621	146.1427

Tabla 1 – Estadística descriptiva sobre los rendimientos.

La media aritmética tiene un valor próximo a cero, cómo ya comentamos anteriormente, los *compound return* oscilan en torno a cero. Por otra parte las medianas difieren ligeramente mayores de la media, lo cual es un síntoma de asimetría a la izquierda. Decimos que hay asimetría derecha si hay más peso en la cola derecha de la distribución, y que hay asimetría izquierda si hay más peso en la cola izquierda.

Para medir la asimetría, se ha calculado el coeficiente de asimetría g_1 de *Fisher-Pearson* [19], definido como:

$$g_1 = \frac{m_3}{m_2^{3/2}}$$

donde

$$m_i = \frac{1}{T} \sum_{t=1}^T (Y_t - \bar{Y})^i$$

donde Y_t es el valor de la serie en el día t , \bar{Y} es la media muestral, T es el total de valores de la muestra, y m_i es el momento centrado de orden i .

m_3 es, para datos distribuidos como una normal, cero. Para distribuciones continuas unimodales, un valor g_1 mayor que cero significa que hay asimetría derecha [19]. Como podemos apreciar en la tabla las tres series presentan asimetría, el petróleo y el carbón hacia la derecha y el gas hacía la izquierda.

La curtosis ha sido medida con la definición de *Pearson* [20].

$$g_2 = \frac{m_4}{m_2^2}$$

Todas las series presentan valores mayores que 3 que es el valor de referencia para distribuciones normales, por lo que presentan exceso de kurtosis especialmente la serie del carbón, que podría estar relacionada con la presencia de valores atípicos.

Las tres series presentan un rango de variación similar, aunque el del carbón es ligeramente mayor, lo cual puede estar relacionado también con la presencia de datos atípicos. Y en cuanto a la desviación estándar, el petróleo y el gas tienen mayor valor que el carbón.

A continuación veremos una información más completa con los *Box-plots*, histogramas y los Q-Qplots.

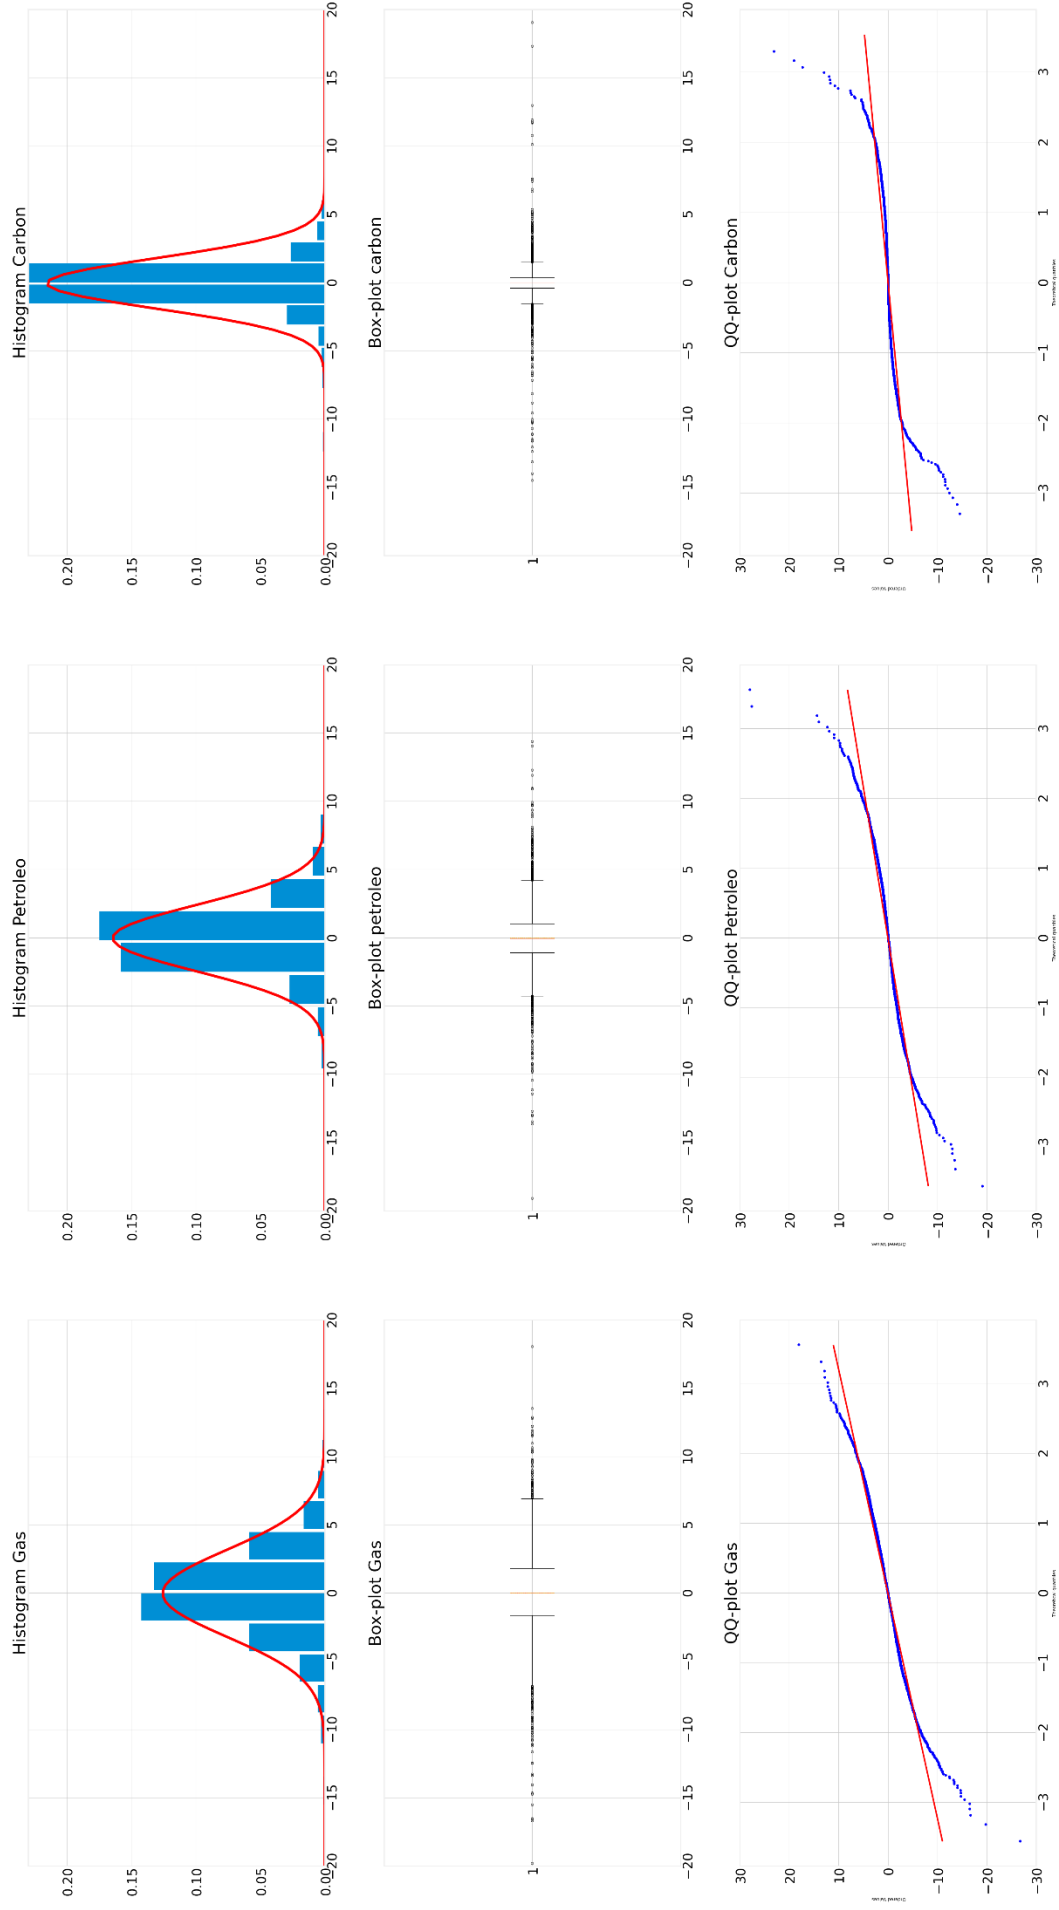


Figura 4- Histogramas junto a función de distribución normal, Box-plots, y QQ-plots.

Si nos fijamos en los histogramas, las distribuciones de los rendimientos presentan forma acampanada pero más picuda que la distribución normal. El histograma del gas es el que más se asemeja a la normal. Y las colas de las distribuciones del petróleo y el carbón son ligeramente más pesadas que las de la normal.

El *Box plot* del gas se asemeja bastante al de una distribución normal. El del petróleo presenta un rango intercuartílico ligeramente más pequeño. Y tanto el del petróleo como el del gas son bastante simétricos, y presentan *outliers*. Por su parte el del carbon, presenta la mayoría de sus valores muy concentrados en torno a la mediana, por eso el gráfico muestra tantos *outliers*.

El Q-Qplot compara los cuantiles teóricos de una distribución conocida (la normal en este caso) frente a los cuantiles muestrales de las series. Los datos se ajustan a la recta si se distribuyen como una normal, y como podemos apreciar este no es el caso, los datos se desvían notablemente al principio y al final de las gráficas, lo cual indica que las colas de las distribuciones de los rendimientos son mas anchas de lo que cabría esperar bajo el supuesto de normalidad. Es decir, es más probable tener valores extremos, debidos a grandes caídas o subidas de precios, que los esperados si la distribución fuese normal. Esto es precisamente lo que caracteriza la curtosis.

Por último, la **Tabla 2** muestra los test de normalidad de Jarque-Bera y Kolmogorov-Smirnov-Lilliefors para las tres series.

	Estadístico (p-value)		
	Gas	Petroleo	Carbón
Jarque-Bera	3089 (0.0)	29762 (0.0)	2920155 (0.0)
Kolmogorov-Smirnov-Lilliefors	0.2150 (0.0)	0.1270 (0.0)	0.1160 (0.0)

Tabla 2- Estadístico y p-values para los contrastes de normalidad de los rendimientos.

El test de Jarque Bera contrasta si la kurtosis y la asimetría se asemejan a los de una normal. Si T es el número total de valores de la serie, y g_1 , g_2 son los coeficientes de asimetría y curtosis que definimos anteriormente, el estadístico de contraste y su distribución asintótica son:

$$d_{JB} = \frac{T}{6} (g_1^2 + \frac{1}{4} (g_2 - 3)^2) \rightarrow \chi_2^2$$

El estadístico d_{JB} tomará valores pequeños si la distribución observada es aproximadamente simétrica y normal. Por el contrario, a medida que se detectan asimetrías, positivas o negativas, o desviaciones en las curtosis, aumenta su valor. Por lo tanto, se rechazará la hipótesis nula de normalidad, si $d_{JB} > \chi_2^2(\alpha)$, al nivel de significación α , siendo $\chi_2^2(\alpha)$ el valor crítico de una chi cuadrado con dos grados de libertad [19]. Como era de esperar este sí es el caso para las tres series analizadas en la distribución.

El test de Kolmogorov-Smirnov-Lilliefors compara la función de distribución teórica $F(x)$ (en este caso de una normal) con la empírica $F_n(x)$ de la muestra. El estadístico es el siguiente:

$$D_n = \max|F_n(x) - F(x)|$$

La distribución de D_n es bien conocida y para no rechazar que los datos se distribuyen como una normal, tiene que ser menor que $d(\alpha)$ para un nivel de significación de α , donde $d(\alpha)$ se obtiene de la tabla de Lilliefors, Fundamentos de Estadística página 471[21].

Los valores obtenidos tanto en el test Kolmogorov-Smirnov como en el de Jarque-Bera rechazan al 1% la hipótesis nula de que las series se distribuyan como una normal puesto que los p-valores son similares a cero y por tanto menores que 0.01.

En la siguiente tabla mostramos el porcentaje de *compound returns* tipificados

$$\frac{(Y_t - \bar{Y}_t)}{S_y}$$

que se encuentran dentro o fuera de determinados intervalos.

	$< \pm 0.5 \sigma$	$> \pm 3 \sigma$	$> \pm 4 \sigma$	$> \pm 5 \sigma$
Distribución Normal	38.2900	0.2700	0.0100	0.00100
Gas	46.8027	1.5300	0.4836	0.1612
Petroleo	54.9329	1.5549	0.5630	0.2949
Carbon	76.6461	1.3462	0.9364	0.7901

Tabla 3-Porcentaje de valores de los rendimientos dentro de $\pm 0.5 \sigma$, y fuera de $\pm 3\sigma$, $\pm 4\sigma$, $\pm 5\sigma$, desde la media.

La primera columna de la tabla muestra que hay más observaciones en el rango $(\bar{Y}_t - 0.5, \bar{Y}_t + 0.5)$ que el esperado de una distribución normal, correspondiéndose con los altos picos de las distribuciones empíricas que veíamos en la **Figura 4**. El resto de filas restantes muestran que también hay más observaciones extremas, más allá de los rangos $(\bar{Y}_t - 3 \sigma, \bar{Y}_t + 3 \sigma)$, $(\bar{Y}_t - 4 \sigma, \bar{Y}_t + 4 \sigma)$ y $(\bar{Y}_t - 5 \sigma, \bar{Y}_t + 5 \sigma)$ correspondiéndose con las colas gruesas.

Por tanto, podemos concluir que en los rendimientos del mercado energético también se cumple el *Stylized Fact* de ausencia de normalidad que mencionábamos al principio del capítulo.

Capítulo 4 – Propiedades dinámicas de los rendimientos

En esta sección vamos a analizar las propiedades dinámicas de las rentabilidades. En concreto, calcularemos las autocorrelaciones de los rendimientos que nos indicarán si hay en estos una dinámica lineal predecible. También veremos si existe efecto Taylor, comparando la autocorrelación en los valores cuadráticos y absolutos, considerados ambos como aproximaciones de la volatilidad. Por último analizaremos el *leverage effect*, viendo si la volatilidad responde de forma asimétrica a caídas y subidas de los precios.

4.1. Incorrelación en los rendimientos

Otro de los *Stylized Facts* bien conocido [2], [10], [17], [18], [22]–[24] y documentado es la ausencia de correlación lineal en los rendimientos de los activos. Si existiese correlación entre los rendimientos podríamos desarrollar un modelo predictivo y una estrategia simple para sacar beneficio con los *futures*.

Para comprobar si existe correlación en los rendimientos empleamos la función de autocorrelación teórica:

$$\rho(h) = \frac{\text{cov}(Y_t, Y_{t-h})}{\text{var}(Y_t)} \text{ con } h = 1, 2, \dots$$

Si denominamos Y_t el rendimiento en t e \bar{Y} la media muestral, el coeficiente de autocorrelación muestral de orden h , que estima al teórico $\rho(h)$ es:

$$\hat{\rho}(h) = \frac{\hat{\gamma}(h)}{\hat{\gamma}(0)} = \frac{\sum_{t=h+1}^T (Y_t - \bar{Y})(Y_{t-h} - \bar{Y})}{\sum_{t=1}^T (Y_t - \bar{Y})^2}, \text{ con } h = 1, 2, \dots$$

Los estimadores de momentos poblacionales empleados en la función de autocorrelación son asintóticamente insesgados bajo los supuestos de estacionariedad y ergodicidad (Diebold 2017 p.141-160) [25].




Figura 5- Función de autocorrelación para los rendimiento, sus valores absolutos y sus cuadrados.

La función de autocorrelación suele representarse junto con las bandas de confianza de *Barlett* al 95%. Estas se definen como $\pm 1,96/\sqrt{T}$, y para la función de autocorrelación de ruido blanco gaussiano aproximadamente el 95% de los valores caerían dentro de estas bandas (Diebold 2017 p.158) [25].

En la **Figura 5** vemos que las correlaciones de los rendimientos son muy bajas y la mayoría no superan las bandas de confianza.

Los correlogramas solamente nos muestran si existe correlación lineal, sin embargo la ausencia de correlación serial no implica la independencia de los rendimientos, independencia implicaría que cualquier función de los rendimientos también carecerá de autocorrelación, y como podemos apreciar este no es el caso, ya que los cuadrados de los rendimientos y los rendimientos absolutos presentan correlaciones significativas incluso en retardos más alejados. Además, las autocorrelaciones de los cuadrados están midiendo la correlación de la volatilidad, y de ahí que presenten valores altos, indicando el *volatility clustering* antes mencionado.

Para completar el análisis de incorrelación serial en los rendimientos vamos a emplear el test de Box-Ljung, que es un contraste de incorrelación lineal conjunta, que emplea el siguiente estadístico:

$$Q(m) = T(T + 2) \sum_{h=1}^m \frac{\{r(h)\}^2}{T - h} \xrightarrow{\text{aprox}} \chi_m^2$$

Este estadístico nos dice si las primeras m autocorrelaciones son 0 conjuntamente (Diebold 2017 p. 158-159) [25]. Valores grandes del estadístico indican correlaciones lineales grandes y rechazan la hipótesis de incorrelación, mientras que valores próximos a cero aceptan la hipótesis nula.

		Gas	Petroleo	Carbón
Ljung-Box (Y_t)	lag=10	31.5211 (0.0004)	15.6053 (0.111499)	27.3952 (0.0)
	lag=25	68.5989 (0.0)	72.4949 (0.0)	115.8446 (0.0)
	lag=50	96.3722 (0.0)	100.736 (0.0)	157.2562 (0.0)
Ljung-Box (Y_t)	lag=10	888.0266 (0.0)	2304.3998 (0.0)	688.2821 (0.0)
	lag=25	1690.4504 (0.0)	4666.6035 (0.0)	1306.3621 (0.0)
	lag=50	2391.9859 (0.0)	6420.1216 (0.0)	1631.7904 (0.0)
Ljung-Box (Y_t^2)	lag=10	450.3095 (0.0)	818.4217 (0.0)	99.8670 (0.0)
	lag=25	809.9639 (0.0)	1835.3564 (0.0)	205.6220 (0.0)
	lag=50	1162.0014 (0.0)	2593.1491 (0.0)	157.2562 (0.0)

Tabla 4- Estadístico y p-valor de Ljung-box test para los rendimientos, su valor absoluto y el curadrado .

Como podemos ver en la tabla hemos obtenidos valores del estadístico bastante grandes, de tal forma que rechazamos la hipótesis de incorrelación para todas las series y todos los retardos analizados, excepto para los rendimientos del petróleo con lag 10.

A continuación calculamos el estadístico Q de Box-Ljung corregido por heteroscedasticidad como propone Diebold (2012)[26].

		Gas	Petroleo	Carbón
Ljung-Box Corregido (Y_t)	lag=10	18.4155 (0.0483)	4.3786 (0.9287)	7.9354 (0.6351)
	lag=25	43.3855 (0.0127)	25.6298 (0.4276)	28.4076 (0.2894)
	lag=50	63.5744 (0.0940)	38.9960 (0.8698)	48.3218 (0.5409)

Tabla 5 – Estadístico y p-valor de Ljung-box test corregido por heteroscedasticidad para los rendimientos.

Este contraste está muy relacionado con utilizar bandas de confianza corregidas por heteroscedasticidad, en lugar de las habituales bandas de Barlett. Cómo podemos apreciar, ahora no rechazamos la hipótesis de ruido blanco (incorrelación) al 5% donde antes si lo hacíamos.

4.2. Autocorrelación en los rendimientos cuadráticos y absolutos. Efecto Taylor.

El interés en los rendimientos cuadráticos y absolutos deriva de que estos están relacionados con la volatilidad de los rendimientos [1], [16].

Si nos fijamos en los correlogramas de $|Y_t|$ y Y_t^2 en la **Figura 5**, podemos apreciar que las correlaciones son positivas, y que la mayoría superan las bandas de confianza. También se puede ver como estas correlaciones son mayores en los primeros lags y después van decreciendo, aunque son significativas para valores de lags altos, Granger y Ding (1995)[1] también se percataron de esto, lo cual es un indicio de memoria larga de la volatilidad. Por otro lado, se puede apreciar que estas correlaciones son mayores para el valor absoluto de los rendimientos que para los rendimientos al cuadrado, cómo veremos más en detalle a continuación.

Taylor (1986) encontró que la autocorrelación del valor absoluto de los rendimientos comúnmente es mayor que la autocorrelación del cuadrado de los rendimientos. Granger y Ding (1995)[1] denominaron a esta regularidad “efecto Taylor”. Formalmente, y de manera más general, Granger y Ding (1995) definen el efecto Taylor de la siguiente manera:

$$\rho_1(h) > \rho_\theta(h)$$

para todo $\theta \neq 1$ donde: $\rho_\theta(h)$ representa la autocorrelación muestral de orden h para $|r_t|^\theta$ con $\theta > 0$. Es más, Granger y Ding (1995) encontraron que la máxima autocorrelación muestral no siempre ocurre cuando $\theta = 1$, sino cuando $0 < \theta < 1$ [17].

Para ver si se cumple la definición del efecto Taylor, en el sentido general, graficamos el coeficiente de autocorrelación de Pearson de $|Y_t|^\theta$ para diferentes lags (1, 5, 10, 20, 40) y para distintos valores de θ representados en el eje abscisas:




Figura 6 – Correlación entre $|Y_t|^\theta$ y $|Y_{t-h}|^\theta$ para diferentes θ , siendo Y_t el rendimiento de cada commodity.

Como podemos apreciar en la **Figura 6** el efecto de Taylor se produce en las tres series, pero no de manera exacta; en casi todos los retardos y en las tres series, observamos que las máximas autocorrelaciones se dan en torno a $\theta \approx 1$, es decir, en los valores absolutos de los rendimientos, aunque en algunos casos el máximo se alcanzan en potencias mayores que uno, pero menores que 1.5. También se ve claramente como al aumentar θ convergen hacia cero, y que los valores máximos aparecen en los puntos de inflexión.

Además, podemos ver como las correlaciones de orden pequeños, son mayores que las de orden 40, como cabía esperar, aunque luego esta serie converge hacia 0 más lenta que las demás.

Por tanto, podemos concluir que los rendimientos energéticos presentan características similares a los rendimientos de los activos financieros en el sentido de que:

- a) Presentan una correlación positiva y persistente en los rendimientos absolutos y cuadráticos.
- b) Las correlaciones de los rendimientos absolutos tienden a ser mayores que las de sus cuadrados (efecto Taylor).

4.3. Efecto Leverage

Es bien conocido que las series temporales de rendimientos financieros son condicionalmente heteroscedásticas con volatilidades que responden asimetricamente a rendimientos pasados negativos y positivos [16], [27], [28], es decir, una rentabilidad negativa (caída de precios) genera mayor incertidumbre sobre el futuro que una rentabilidad positiva (subida de precios) y por ello genera un periodo de mayor volatilidad. Esto es conocido como *leverage effect*.

La identificación de *leverage effect* esta basada comúnmente en la correlación cruzada muestral entre rendimientos pasados Y_{t-h} y valores futuros Y_t^2 , estos últimos están relacionados con la volatilidad subyacente. Si el aumento de la volatilidad es mayor en respuesta a rendimientos pasados negativos que positivos de la misma magnitud, entonces las correlaciones cruzadas entre Y_{t-h} e Y_t^2 son negativas. Por lo tanto, los valores negativos de estas correlaciones cruzadas indican un posible efecto Leverage. Sin embargo, se sabe que ante la aparición de outliers las correlaciones cruzadas no son robustas y es mejor emplear medidas robustas.




Figura 7-Correlación cruzada entre los rendimientos y sus cuadrados, y los rendimientos y sus absolutos.

Como podemos apreciar en la ***Figura 7***, en los rendimientos del carbón es donde más correlaciones negativas aparecen, aunque la mayoría no son significativas pero las primeras lo son claramente. En cuanto al gas y el petróleo, parece no producirse el efecto *Leverage*. Estos resultados contradicen los resultados obtenidos en Carnero y Pérez, 2019 [27] y Kristoufek, 2014 [28] donde se confirma la existencia de efecto *Leverage* en los rendimientos del petróleo Brent y WTI, pero no para los rendimientos del gas para un período temporal que abarca desde el 4 de junio del 2000 hasta el 28 de junio de 2001. Aunque esto podría deberse al análisis de periodos temporales distintos, o al uso de precios de cierre (close-close) en vez de precios de apertura (open-open).

Capítulo 5 – Sensibilidad de los resultados ante la presencia de datos atípicos. Medidas de correlación robustas.

Cuando una pequeña fracción de la muestra (entre el 1 y el 10%) aparece como atípica, el efecto de esta heterogeneidad puede ser muy grave: supongamos una muestra de T observaciones de una población (μ_0, σ_0) donde, por error, uno de los datos proviene de una población distinta (μ_1, σ_1) . Entonces:

$$E[\bar{x}] = \frac{T-1}{T} \mu_0 + \frac{1}{T} \mu_1$$

La media muestral será un estimador sesgado. Si μ_1 es mucho mayor que μ_0 , y T no es muy grande, la media muestral tendrá un error alto como estimador de μ_0 . Su varianza será:

$$var(\bar{x}) = \frac{\sigma_0^2}{T} \left(1 + \frac{k^2 - 1}{T} \right)$$

Donde k es una variable arbitraria positiva, y si esta toma un valor grande, la varianza puede ser arbitrariamente grande. Por tanto, una única observación muy atípica puede alterar todas las propiedades de los estimadores. D. Peña, Fundamentos de estadística P.514[21]. Maronna, Martin y Yohai (2006) muestran que un atípico aislado sesga todas las autocorrelaciones hacia 0 y dos outliers consecutivos sesgan la primera autocorrelación hacia 0.5 ó -0.5 y el resto hacia 0. Carnero, Peña y Ruiz (2006) prueban resultados similares para las autocorrelaciones de los cuadrados. Carnero 2016 [29] muestra que las correlaciones cruzadas no son robustas ante la presencia de valores atípicos y podrían dar lugar a resultados engañosos, por lo que en Carnero y Pérez, 2019 [27] emplean estimadores robustos para calcular las correlaciones cruzadas. Nosotros también haremos uso de estimadores robustos, en las siguientes secciones calcularemos la autocorrelación robusta de los rendimientos, la de los rendimientos al cuadrado, y finalmente, veremos el estimador robusto de las correlaciones cruzadas, para así poder compararlas con los resultados obtenidos en las secciones anteriores. Aunque los estimadores robustos no son la única solución al problema de los valores atípicos, por ejemplo en Granger y Ding, 1994 [1] llevan a cabo una reducción de *outliers* (eliminando valores que superen 4 veces la desviación estándar estimada).

5.1. Estimador robusto de la autocorrelación.

Cómo comentábamos arriba el estimador de la media y la varianza se encuentra sesgado ante la presencia de un *outlier* grande. En Timo Teräsvirta & Zhenfang Zhao (2011) [30] se comprueba como el uso de estimadores no robustos proporcionan coeficientes de correlación mayores que los de los estimadores robustos, lo cual puede dificultar la detección del efecto Taylor.

El estimador robusto de la autocovarianza propuesto en [30] para calcular la función de autocorrelación vista anteriormente en la sección 4.1 es:

$$\tilde{\gamma}(h) = \frac{\sum_{t=h+1}^T (Y_{t-h} - \bar{Y}_w) (Y_t - \bar{Y}_w) w_{t-h} w_t}{\sum_{t=h+1}^T w_{t-h} w_t}, \text{ con } h = 0, 1, 2, \dots$$

donde

$$\bar{Y}_w = \frac{\sum_{t=1}^T Y_t w_t}{\sum_{t=1}^T w_t}$$

y el termino w_t se corresponde con los pesos de Ramsay (1977)

$$w_t = \exp\left(-a_2 \frac{|Y_t - \bar{Y}|}{\hat{\sigma}(Y_t)}\right)$$

donde \bar{Y} , y $\hat{\sigma}$ son la media y la desviación típica de los datos, los cuales estimaremos igual que anteriormente. Como podemos apreciar en la fórmula, todas las observaciones con valores diferentes a la media son disminuidos exponencialmente, en la medida que se alejen de la media y en comparación con la desviación estándar. Siguiendo la recomendación de T. Teräsvirta y Zhao (2011)[30], utilizaremos $a_2 = 0.3$.

A partir de la función de autocovarianza robusta se define la autocorrelación robusta como:

$$\tilde{\rho}(h) = \frac{\tilde{\gamma}(h)}{\tilde{\gamma}(0)}, \quad h = 1, 2, \dots$$

En la siguiente figura podemos ver las funciones de autocorrelación obtenidas con este estimador y los que explicaremos en las siguientes secciones.

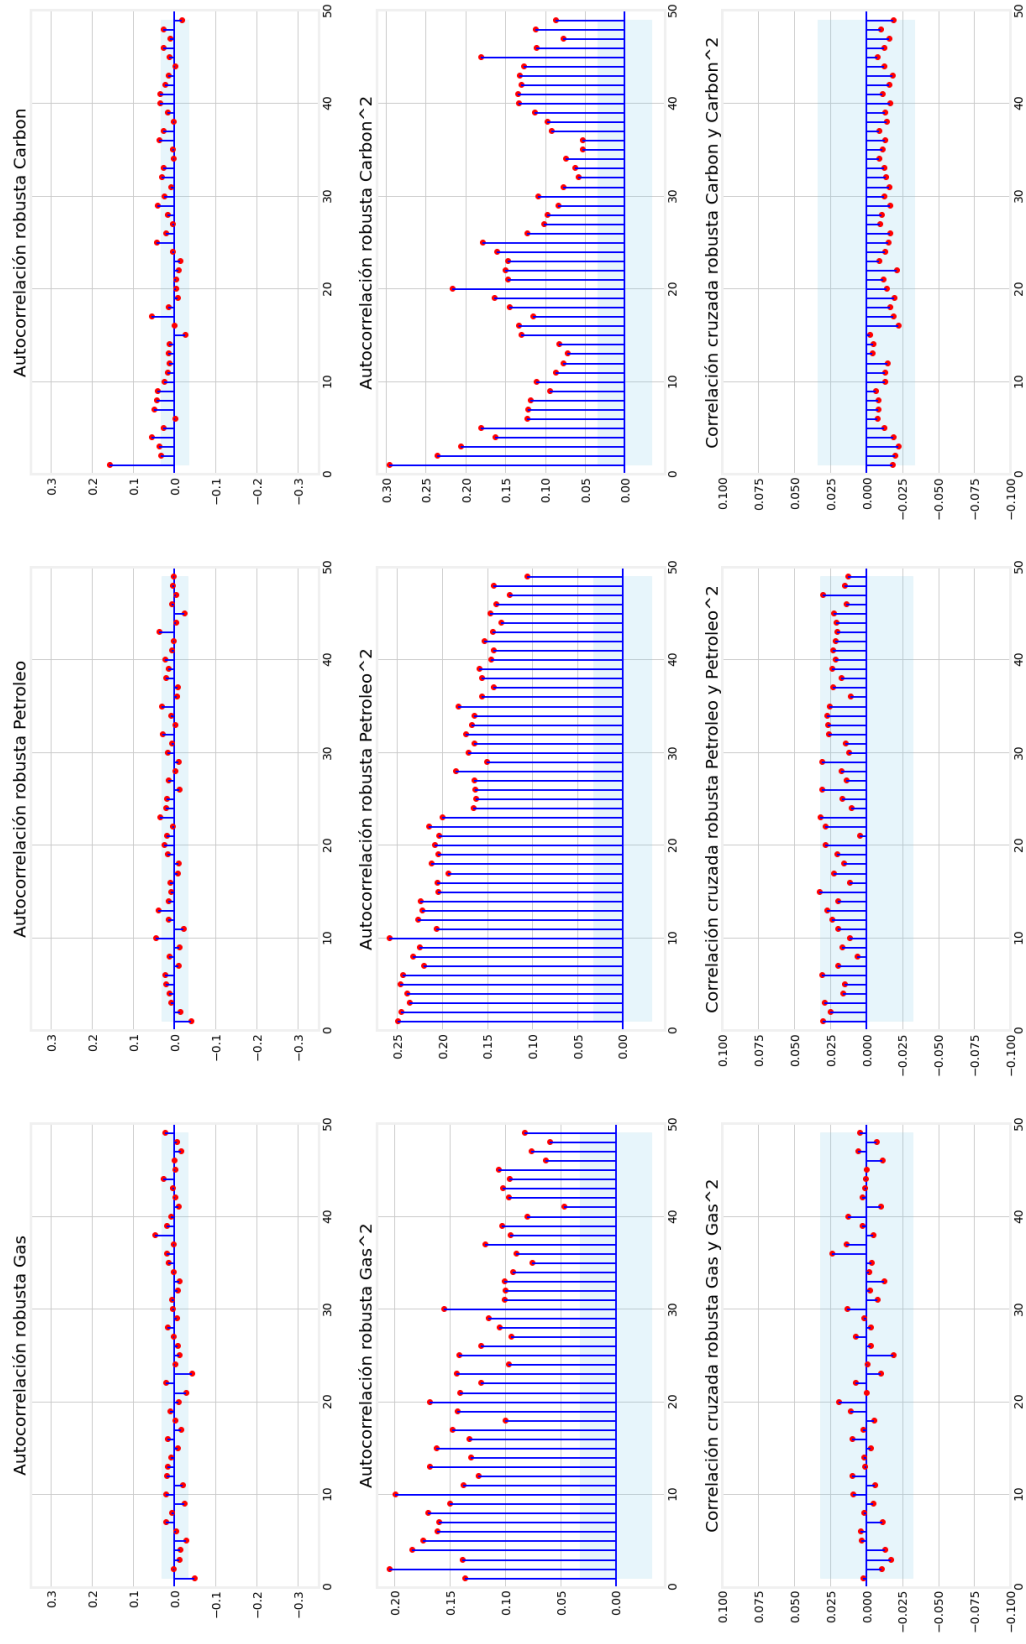


Figura 8-Funciones de autocorrelación de los rendimientos, autocorrelación de los rendimientos al cuadrado y correlaciones cruzadas entre los rendimientos y los rendimientos al cuadrado.

Como podemos observar en la **Figura 8**, la función de autocorrelación del gas presenta más valores significativos que antes, aunque aún así estos valores son bajos, lo mismo pasa si nos fijamos en los rendimientos del petróleo, por su parte, los rendimientos del carbón, no difieren mucho de los resultados obtenidos anteriormente.

5.2. Estimador robusto de la autocorrelación de los cuadrados.

A la hora de calcular la autocorrelación de los rendimientos al cuadrado en presencia de datos atípicos tenemos los mismos problemas comentados en la anterior sección, y los analizados en Carnero, Peña y Ruiz (2006) [31]. Por ello, recurrimos al uso de un estimador robusto. El estimador robusto de la autocovarianza de los rendimientos al cuadrado, que denotaremos como $\tilde{\gamma}_2(h)$, se define como:

$$\tilde{\gamma}_2(h) = \frac{\sum_{t=h+1}^T (Y^2_{t-h} - \overline{Y^2_w}) (Y^2_t - \overline{Y^2_w}) w^2_{t-h} w^2_t}{\sum_{t=h+1}^T w^2_{t-h} w^2_t}, h = 0, 1, 2, \dots$$

Donde $\overline{y^2_w}$ es una media ponderada de los cuadrados definida como:

$$\overline{y^2_w} = \frac{\sum_{t=1}^T Y^2_t w^2_t}{\sum_{t=1}^T w^2_t}$$

A partir de estas funciones se define la autocorrelación robusta de los cuadrados como:

$$\tilde{\rho}_2(h) = \frac{\tilde{\gamma}_2(h)}{\tilde{\gamma}_2(0)} \text{ con } h = 1, 2, \dots$$

Todas las autocorrelaciones robustas de cuadrados en la **Figura 8** son mayores que las autocorrelaciones de cuadrados no robustas y más parecidas a las de los rendimientos absolutos en la **Figura 5**. Esto concuerda con los resultados teóricos de Carnero, Peña y Ruiz (2006)[31].

5.3. Estimador robusto de las autocorrelaciones cruzadas.

Al igual que en los dos casos anteriores, la presencia de atípicos puede sesgar los valores de las correlaciones cruzadas. De hecho, un único valor atípico grande sesga las correlaciones cruzadas hacia cero y, por lo tanto, podría ocultar el efecto Leverage. Por otro lado, la presencia de dos o más valores atípicos consecutivos grandes podría conducir a la detección de asimetrías espurias o asimetrías de signo equivocado Carnero, Perez y Ruiz 2016 [29].

Por ello, vamos a calcular las versiones robustas de las correlaciones cruzadas de los rendimientos con los rendimientos al cuadrado que empleamos en la sección anterior para comprobar la presencia de efecto *Leverage*. En este caso utilizaremos el estimador robusto propuesto en [29] es

$$r_{12,w}(h) = \frac{\tilde{\gamma}_{12}(h)}{\sqrt{\tilde{\gamma}(0)\tilde{\gamma}_2(0)}}$$

donde

$$\tilde{\gamma}_{12}(h) = \frac{\sum_{t=h+1}^T (Y_{t-h} - \bar{Y}_w) (Y_t^2 - \bar{Y}_w^2) w_{t-h} w_t^2}{\sum_{t=h+1}^T w_{t-h} w_t^2}$$

y $\tilde{\gamma}(0)$ y $\tilde{\gamma}_2(0)$ denotan los estimadores robustos de la varianza de Y_t e Y_t^2 , definidos en las secciones 5.1, y 5.2 respectivamente. Y en cuanto a w_t , son los pesos de Ramsay que vimos anteriormente.

Como podemos apreciar en la **Figura 8**, las correlaciones obtenidas no son significativas, por lo que no se confirma la presencia de efecto *Leverage* para ninguna de las tres series, lo cual difiere con los resultados obtenidos en M.Ángeles, Ana Pérez, 2019 [27]. Es más, las correlaciones cruzadas del petróleo son positivas, y estarían detectando “inverse” leverage-effect, es decir, que grandes cambios positivos darían lugar a mayores aumentos de la volatilidad que grandes cambios negativos. En Zhang et al. (2008)[32] justifican este efecto argumentando que cuando el precio del petróleo aumenta, la expectativa es que la oferta de petróleo disminuirá, lo que hace que los comerciantes compren petróleo lo antes posible aumentando aún más el precio del petróleo y también su volatilidad. Con respecto al crudo Brent, Kristoufek (2014)[28], Fan et al. (2008)[32] encuentran que no hay efecto de apalancamiento en los rendimientos del Brent. Además, Wei et al. (2010)[33] encuentran resultados mixtos para el Brent pero también para la rentabilidad del WTI.

Capítulo 6 - Conclusiones

Este trabajo analiza las propiedades dinámicas y marginales de la distribución de los rendimientos del mercado energético (petróleo, gas y carbón) con el fin de ver si cumplen una serie de características (*Stylized Facts*) que ya han sido ampliamente documentadas en los rendimientos de los activos financieros.

Estas son las conclusiones que obtenemos de este trabajo:

- Las distribuciones empíricas de los compound returns tienen forma acampanada pero no se distribuyen como una normal.
- La volatilidad de las series no es constante y aparece agrupada.
- Ausencia de correlación lineal de los rendimientos, pero presencia en la volatilidad, llegando a haber incluso *long memory*.
- Se produce efecto Taylor pero no de manera estricta, ya que el coeficiente de autocorrelación máximo no se produce justo en $\theta = 1$ si no, en valores cercanos a uno.
- No podemos confirmar que se cumpla el efecto *Leverage* en ninguna de las tres series.

Por tanto vemos que los rendimientos del mercado energético comparten algunos *Stylized Facts* de los rendimientos financieros como son la forma acampanada de la distribución empírica, el *volatility clustering*, la ausencia de correlación lineal en los rendimientos, y el efecto Taylor, pero no otros como el *Leverage Effect*.

Referencias

- [1] C. W. J. Granger y Z. Ding, «Stylized Facts on the Temporal and Distributional Properties of Daily Data from Speculative Markets». Rochester, NY, 14 de septiembre de 1999. Accedido: 26 de septiembre de 2022. [En línea]. Disponible en: <https://papers.ssrn.com/abstract=5766>
- [2] R. Rapier, «The Ten Countries That Dominate World Fossil Fuel Production», *Forbes*. <https://www.forbes.com/sites/rrapier/2019/07/14/ten-countries-that-dominate-fossil-fuel-production/> (accedido 15 de mayo de 2022).
- [3] Directorate-General for Energy (European Commission), *EU energy in figures: statistical pocketbook 2021*. LU: Publications Office of the European Union, 2021. Accedido: 15 de mayo de 2022. [En línea]. Disponible en: <https://data.europa.eu/doi/10.2833/511498>
- [4] «Shedding light on energy in the EU: From where do we import energy?», *Shedding light on energy in the EU*. <https://ec.europa.eu/eurostat/cache/infographs/energy/bloc-2c.html> (accedido 15 de mayo de 2022).
- [5] «¿Qué son los commodities? Tipos y ejemplos | Blog UE». <https://universidadeuropea.com/blog/que-son-los-commodities/> (accedido 15 de mayo de 2022).
- [6] elEconomista.es, «Los “shocks” del petróleo históricamente se saldan con caídas bursátiles en torno al 10%». <https://www.eleconomista.es/mercados-cotizaciones/noticias/2791556/02/11/Los-shocks-del-petroleo-historicamente-se-saldan-con-caidas-bursatiles-en-torno-al-10.html> (accedido 18 de julio de 2022).
- [7] «Risk Management in Energy Markets», en *Energy Markets*, John Wiley & Sons, Ltd, 2012, pp. 1-8. doi: 10.1002/9781119207740.ch1.
- [8] D. Peña, *Análisis de series temporales*. Grupo Anaya Comercial, 2005.
- [9] «How Should Relative Changes be Measured?: The American Statistician: Vol 39, No 1». <https://www.tandfonline.com/doi/abs/10.1080/00031305.1985.10479385> (accedido 27 de septiembre de 2022).
- [10] S. J. Taylor, *Asset Price Dynamics, Volatility, and Prediction*, STU-Student edition. Princeton University Press, 2005. Accedido: 14 de enero de 2023. [En línea]. Disponible en: <https://www.jstor.org/stable/j.ctt7t66m>
- [11] «Energy Futures Prices», *Investing.com*. <https://www.investing.com/commodities/energy> (accedido 19 de junio de 2022).
- [12] C. R. Urdiales, «Cesuur/energy-market-analysis». 31 de mayo de 2022. Accedido: 26 de octubre de 2022. [En línea]. Disponible en:

<https://github.com/Cesuuur/energy-market-analysis/blob/27c062a70329be75ec4c69b7a0bdaffac10d9920/CompoundReturnAnalysis.ipynb>

- [13] S. A. Patterson Gerben Hieminga, Warren, «Carbon prices in the EU crash despite rising fossil fuel prices», *ING Think*. <https://think.ing.com/articles/carbon-prices-in-the-eu-crash-despite-rising-fossil-fuel-prices/> (accedido 8 de junio de 2022).
- [14] BBVA, «BBVA Research: ¿Qué puede pasar en el mundo de las commodities posguerra Rusia - Ucrania?», *BBVA NOTICIAS*, 29 de abril de 2022. <https://www.bbva.com/es/bbva-research-el-futuro-de-los-commodities-ante-el-conflicto-rusia-ucrania/> (accedido 14 de mayo de 2022).
- [15] M. Pronczuk, «European Union countries agree to jointly purchase gas.», *The New York Times*, 25 de marzo de 2022. Accedido: 15 de mayo de 2022. [En línea]. Disponible en: <https://www.nytimes.com/2022/03/25/business/european-union-gas-russia.html>
- [16] E. Ruiz Ortega y M. H. Veiga, «Modelos de volatilidad estocástica: una alternativa atractiva y factible para modelizar la evolución de la volatilidad», *An. Estud. Económicos Empres.*, n.º 18, pp. 9-68, 2008.
- [17] J. C. Alonso y G. Torres, «Características estadísticas del índice general de la Bolsa de Valores de Colombia (IGBC) en sus primeros 10 años», *J. Econ. Finance Adm. Sci.*, vol. 19, n.º 36, pp. 45-54, jun. 2014, doi: 10.1016/j.jefas.2014.03.001.
- [18] R. Cont, «Empirical properties of asset returns: stylized facts and statistical issues», *Quant. FINANCE*, p. 14.
- [19] «scipy.stats.skew — SciPy v1.8.1 Manual». <https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.skew.html> (accedido 8 de junio de 2022).
- [20] «1.3.5.11. Measures of Skewness and Kurtosis». <https://www.itl.nist.gov/div898/handbook/eda/section3/eda35b.htm> (accedido 3 de julio de 2022).
- [21] D. Peña, *Fundamentos de Estadística*. Alianza Editorial, 2014.
- [22] A. Humala y G. Rodríguez, «Some stylized facts of returns in the foreign exchange and stock markets in Peru», *Algunos hechos estilizados sobre los retornos en los mercados de cambios y valores en el Perú*, 2011, Accedido: 7 de junio de 2022. [En línea]. Disponible en: <https://repositorio.pucp.edu.pe/index/handle/123456789/46966>
- [23] F. Aparicio y J. Estrada, «Empirical Distributions of Stock Returns: European Securities Markets, 1990-95». Rochester, NY, 1 de abril de 1997. doi: 10.2139/ssrn.40558.
- [24] S. J. Taylor, *Modelling Financial Time Series*. World Scientific, 2008.

- [25] F. X. Diebold, «Forecasting in Economics, Business, Finance and Beyond», 2017, [En línea]. Disponible en: <https://www.sas.upenn.edu/~fdiebold/Teaching221/Forecasting.pdf>
- [26] F. X. Diebold, *Empirical Modeling of Exchange Rate Dynamics*. Springer Science & Business Media, 2012.
- [27] M. Á. Carnero y A. Pérez, «Leverage effect in energy futures revisited», *Energy Econ.*, 2018, doi: 10.1016/j.eneco.2017.12.029.
- [28] L. Kristoufek, «Leverage effect in energy futures», *Energy Econ.*, vol. 45, pp. 1-9, sep. 2014, doi: 10.1016/j.eneco.2014.06.009.
- [29] M. Á. Carnero, A. Pérez, y E. Ruiz, «Identification of asymmetric conditional heteroscedasticity in the presence of outliers», *SERIEs Journal Span. Econ. Assoc.*, n.º 7, pp. 179-201, 2016, doi: 10.1007/s13209-015-0131-4.
- [30] T. Teräsvirta y Z. Zhao†, «Stylized facts of return series, robust estimates and three popular models of volatility», *Appl. Financ. Econ.*, vol. 21, n.º 1-2, pp. 67-94, ene. 2011, doi: 10.1080/09603107.2011.523195.
- [31] M. A. Carnero, D. Peña, y E. Ruiz, «Effects of outliers on the identification and estimation of GARCH models», *J. Time Ser. Anal.*, vol. 28, n.º 4, pp. 471-497, 2007, doi: 10.1111/j.1467-9892.2006.00519.x.
- [32] Y. Fan, Y.-J. Zhang, H.-T. Tsai, y Y.-M. Wei, «Estimating ‘Value at Risk’ of crude oil price and its spillover effect using the GED-GARCH approach», *Energy Econ.*, vol. 30, n.º 6, pp. 3156-3171, nov. 2008, doi: 10.1016/j.eneco.2008.04.002.
- [33] Y. Wei, Y. Wang, y D. Huang, «Forecasting crude oil market volatility: Further evidence using GARCH-class models», *Energy Econ.*, vol. 32, n.º 6, pp. 1477-1484, nov. 2010, doi: 10.1016/j.eneco.2010.07.009.